CƠ SỞ LÝ THUYẾT & CẤU TRÚC MÃ NGUỒN

HỆ THỐNG HỎI - ĐÁP TRÊN TÀI LIỆU DỰA TRÊN RAG

Khoa Khoa học và Kỹ thuật Máy tính
Trường Đại học Bách Khoa — ĐHQG TP. Hồ Chí Minh

Ngày 6 tháng 11 năm 2026

1. INPUT

Vấn đề giải quyết

Hệ thống giải quyết bài toán ánh xạ tất định từ tập tài liệu nguồn D và câu hỏi tự nhiên q:

$$\mathcal{F} : (D, q) \longmapsto (a, E)$$

INPUT

- **D**: Tập tài liệu nguồn đa định dạng (`.pdf`, `.docx`, `.txt`), được tổ chức và phân hoạch theo các **Partitions** độc lập nhằm cách ly ngữ cảnh.
- **q**: Câu hỏi truy vấn ngôn ngữ tự nhiên từ người dùng, được tự động chuẩn hóa và viết lại (*Contextual Query Rewriting*) khi xử lý hội thoại đối thoại đa lượt.

2. OUTPUT BÀI TOÁN

OUTPUT

- **a**: Câu trả lời tự nhiên, tường minh từ mô hình sinh, tuân thủ chặt chẽ nguyên tắc **Closed-World** nhằm triệt tiêu hiện tượng ảo giác (*Hallucination*).
- $\mathbf{E} = \{e_1, \ldots, e_k\}$: Tập hợp các bằng chứng kiểm toán minh bạch (*Auditable Evidences*):

$$e_i = (\text{id}, \text{chunk}, \text{source}, \text{page}, \tau \geq 0.50)$$

Ý nghĩa của ràng buộc

Mỗi kết luận được đưa ra đều bắt buộc phải liên kết trực tiếp tới tọa độ trang và trích đoạn văn bản gốc trong tài liệu quy chế.

3. TIỀN XỬ LÝ TÀI LIỆU

Chuẩn hóa NFC Tiếng Việt

- Chuyển đổi mã Unicode tổ hợp (NFD) về dạng dựng sẵn (**NFC**).
- Loại bỏ triệt để các ký tự rác hệ thống (như khoảng trắng không ngắt).
- Gom cụm các dòng trống lặp (≥ 3 dòng).
- Lọc sạch dấu câu nhiễu hai đầu truy vấn.

Trích xuất Bảng Biểu

- Sử dụng thư viện **PyMuPDF** phân tích tọa độ trực tiếp.
- Tự động trích xuất bảng biểu cấu trúc thành định dạng **Markdown Table**:

```
| Mã MH | Tín chỉ | Điểm |
```

- Giữ cấu trúc quan hệ hàng - cột của các biểu phí và quy chế đào tạo.

4. PHÂN ĐOẠN DỮ LIỆU

Cơ Chế Sliding Window Snapping

- Tham số cửa sổ trượt: Kích thước khối $L = 900$, khoảng chồng lấp $\Delta = 100$.
- Dò lùi tối đa 60 ký tự để bắt điểm ngắt ranh giới câu tự nhiên:

$$\mathcal{B} = \{\texttt{\textbackslash n\textbackslash n}, \texttt{.\textbackslash n}, \texttt{. }, \texttt{? }, \texttt{! }\}$$

- Ngăn ngừa hiện tượng ngắt đôi cấu trúc vị ngữ câu, bảo đảm ngữ nghĩa trọn vẹn.

Truy xuất Tọa Độ

Mỗi phân đoạn văn bản đều lưu trữ bộ định danh tọa độ trích xuất nguyên tử:

$$\text{Chunk} = (\text{id}, \text{source}, \text{partition}, \text{page}, \text{char_start}, \text{char_end})$$

Dense Retrieval: Mô hình BGE-M3 (1024-D)

- Sử dụng mô hình nhúng đa ngôn ngữ tiên tiến `BAAI/bge-m3`.
- Vector đầu ra được chuẩn hóa theo độ dài L_2:

$$\hat{\mathbf{v}} = \frac{\mathbf{v}}{\|\mathbf{v}\|_2} \implies \|\hat{\mathbf{v}}\|_2 = 1.0$$

- Tích vô hướng tương đương độ tương đồng Cosine:

$$\langle \hat{\mathbf{u}}, \hat{\mathbf{v}} \rangle = \cos(\mathbf{u}, \mathbf{v})$$

- Trích xuất tập ứng viên có ngữ nghĩa sâu: **Top 15 Chunks**.

6. SPARSE LEXICAL & QUERY REWRITING

Sparse Lexical Matcher: Thuật Toán BM25Plus

- Tận dụng Okapi BM25Plus với hệ số chặn dưới $\delta = 1.0$:

$$\text{Score}(d, q) = \sum_{t \in q} \text{IDF}(t) \left[\frac{\text{TF}(k_1 + 1)}{\text{TF} + k_1(1 - b + b\frac{|d|}{\text{avgdl}})} + \delta \right]$$

- Không phạt quá mức văn bản dài; bắt chính xác 100% mã học phần (`CO3101`), tên giảng viên, thuật ngữ viết tắt.
- Thu hồi tập ứng viên từ khóa: **Top 15 Chunks**.

Contextual Query Rewriting

Khử đại từ thay thế qua lịch sử đối thoại. VD: *"Nó có mấy tín chỉ?"* $\longrightarrow$ ***"Môn học CO3101 có bao nhiêu tín chỉ?"***

7. CHỈ MỤC ĐỒ THỊ HNSW

Chỉ mục Đồ thị FAISS HNSW Flat

- Cấu trúc thế giới nhỏ phân tầng (*Hierarchical Navigable Small World Graph*).
- **Siêu tham số thực nghiệm tối ưu:**
  - $M = 16$: Số liên kết hai chiều tối đa cho mỗi nút đồ thị.
  - efConstruction $= 200$: Độ sâu khám phá không gian khi khởi tạo chỉ mục.
  - efSearch $= 50$: Kích thước hàng đợi ưu tiên trong lúc truy vấn.
- Độ phức tạp tìm kiếm $\mathcal{O}(\log N)$, độ trễ < 5ms, tỷ lệ Recall $> 98\%$.

Tái Tạo Vector Tức Thời (`IndexHNSWFlat.reconstruct_n`)

Hỗ trợ xóa tài liệu trong vài mili-giây trực tiếp từ bộ nhớ RAM mà **hoàn toàn không cần tính lại Embedding**!

8. HỢP NHẤT THỨ HẠNG RRF (Reciprocal Rank Fusion)

Thuật Toán Reciprocal Rank Fusion (Cormack et al., SIGIR)

- Dung hợp vị trí xếp hạng tương hỗ từ hai nhánh tìm kiếm Dense và Sparse:

$$\mathrm{RRF}(d) = \sum_{m \in \{\mathrm{Dense}, \mathrm{Sparse}\}} \frac{1}{k_{\mathrm{rrf}} + r_m(d)}$$

- Hằng số làm mịn: $k_{\mathrm{rrf}} = 60$.
- Hoàn toàn không phụ thuộc vào thang điểm tuyệt đối khác biệt giữa Cosine Similarity và BM25.
- Chọn lọc ra **Top 10 Chunks** ứng viên ưu tú nhất đưa sang tầng Reranker.

9. RERANKER & LỌC NGƯỠNG TƯƠNG QUAN

Cross-Encoder Reranker (`bge-reranker-v2-m3`)

- Khác biệt với Bi-Encoder, Cross-Encoder kích hoạt **Full Cross-Attention** giữa câu hỏi và đoạn trích:

$$x = [\text{CLS}] \circ q \circ [\text{SEP}] \circ c \circ [\text{SEP}]$$

- Điểm tương quan thô s được chuẩn hóa qua hàm **Sigmoid**:

$$\tau = \sigma(s) = \frac{1}{1 + e^{-s}} \in [0.0, 1.0]$$

- Đánh giá chính xác quan hệ ngữ nghĩa ở cấp độ token.

Lọc Nhiễu ($\tau \geq 0.50$)

- Kiểm tra:

$$\text{chunk.score} \geq 0.50$$

- Nếu không có đoạn trích nào đạt chuẩn: **Dừng gọi LLM**, trả về thông báo không đủ căn cứ, tiết kiệm 100% chi phí API và ngăn chặn ảo giác.

Top-k Context ($k = 3$)

Chỉ đưa đúng 3 bằng chứng có τ cao nhất vào ngữ cảnh, triệt tiêu hiện tượng *"Lost in the Middle"*.

10. CHỐNG ẢO GIÁC & GÁN NHÃN BẰNG CHỨNG

Thế Giới Đóng

- Áp đặt System Prompt.
- LLM (Google Gemini Flash) bị cấm sử dụng tri thức ngoài ngữ cảnh được cung cấp.

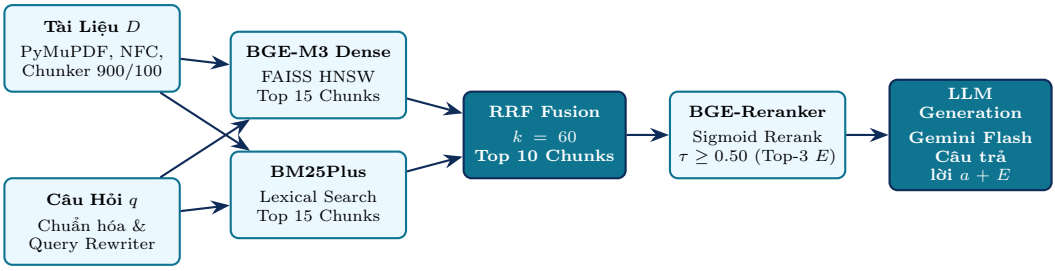
Gán Nhãn Trích Dẫn $[i]$

- Mọi nhận định trong câu trả lời bắt buộc gắn nhãn tham chiếu: $[1]$, $[2]$ hoặc $[1, 3]$.
- Đối soát với số trang và tên file nguồn.

Extractive Fallback

- Cơ chế tự động kích hoạt khi mất mạng Internet hoặc không có API Key.
- Trích xuất đoạn văn bản trọng số cao nhất tại chỗ, không làm gián đoạn hệ thống.

11. KIẾN TRÚC HỆ THỐNG (5-Step Pipeline)



12. SOURCE CODE & KIẾN TRÚC TÁCH LỚP (SoC)

Sơ đồ

```
CO3101/
|-- data/raw/            # Tai lieu va
    partitions
|-- src/
|   |-- config.py        # Sieu tham so tap
    trung
|   |-- schemas.py       # Pydantic v2 Models
|   |-- pipeline.py      # RagPipeline dieu
    phoi
|   |-- ingestion/       # loader.py, chunker
    .py
|   |-- retrieval/       # hnsw, bm25, rerank
|   |-- generation/      # llm_client.py
|   `-- ui/              # FastAPI & Web SPA
|-- storage/faiss_index/# index.bin &
    metadata
|-- tests/               # test_optimizations
    .py
`-- main.py              # CLI Runner tuong
    tac
```

Lớp Kiến Trúc

- **Domain Schemas (`schemas.py`):** Kiểm soát kiểu nghiêm ngặt (`Chunk`, `Evidence`, `RagResponse`).
- **Ingestion Engine (`src/ingestion/`):** Tách biệt hoàn toàn tầng nạp tệp và phân tách khối văn bản.
- **Retrieval Subsystem (`src/retrieval/`):** Độc lập giữa Embedding, HNSW Store, BM25 và Cross-Encoder.
- **High-Speed SPA UI (`src/ui/`):** FastAPI bất đồng bộ, tốc độ tải trang < 50ms.

13. TÍNH NĂNG BỔ TRỢ

Xóa Tệp Tức Thời Từ RAM

Sử dụng `IndexHNSWFlat.reconstruct_n` để lọc các vector giữ lại và thêm trực tiếp vào chỉ mục mới. Không tiêu tốn tài nguyên GPU/CPU tính lại embedding.

Phân Vùng Dữ Liệu

Tách biệt hoàn toàn các lĩnh vực tri thức. Lọc triệt để ngay tại tầng metadata, triệt tiêu nhiễu chéo.

Nạp Gia Tăng

Lệnh `main.py -incremental` tự động đối soát tệp đã tồn tại, chỉ tính toán và nhúng vector cho các tài liệu mới thêm vào.

14. GIÁ TRỊ BẢNG THAM SỐ (Hyperparameters)

Tham Số	Giá Trị	Ý Nghĩa
CHUNK_SIZE / OVERLAP	**900 / 100**	Vừa vặn 1–2 điều khoản quy chế; bảo tồn ngữ nghĩa liên kết câu.
EMBEDDING_MODEL	`BAAI/bge-m3`	Bi-Encoder 1024 chiều, chuẩn hóa L_2, tối ưu tiếng Việt.
HNSW (M, efC, efS)	**16, 200, 50**	Cân bằng lý tưởng giữa tốc độ < 5ms và độ chính xác $> 98\%$.
DENSE / SPARSE TOP-K	**15 / 15**	Lấy 15 ứng viên mỗi nhánh để bao phủ cả ngữ nghĩa và từ khóa.
RRF TOP-N / K_RRF	**10 / 60**	Dung hợp thứ hạng tương hỗ, chọn 10 chunks đưa vào reranker.
SIMILARITY_THRESHOLD (τ)	$\geq$ **0.50**	Ngưỡng tương quan sau Sigmoid, lọc sạch 100% tài liệu nhiễu.
LLM TOP-K / MODEL	**3 / Gemini Flash**	Top-3 bằng chứng minh bạch gắn nhãn $[i]$ đưa vào Gemini Flash.